

Relatório - Desafio Quantamental

Desenvolvimento de uma Estratégia Quantitativa

Design Robô	
Nome do Robô	GEF
Explicação Nome	Acrônimo dos nomes dos integrantes da equipe
Explicação Lógica Estratégia	A estratégia busca desenvolver um modelo de aprendizado de máquina por reforço para identificar próximas valorizações dos principais ativos listados no IBOV, através do cruzamento de dados de análise de sentimento, bem como análise técnica, quantitativa e fundamentalista.
Tipo de Estratégia	Trade
Classe de Ativos	Ações
Universo	IBOV
Média Trades por mês	200 a 300
Holding Period	1 a 5 dias
Qual Plataforma Testou a estratégia	Todos os processos serão desenvolvidos utilizando Python
Benchmark Estratégia:	IBOV, preferencialmente, e CDI

Introdução

Em um mundo onde a inteligência artificial tem ganhado cada vez mais destaque nas mais diversas áreas, não poderíamos esperar que no mercado financeiro fosse diferente. Por trás de um conceito abstrato, há um complexo universo de funções matemáticas capazes de se ajustar para modelar fenômenos da realidade. Uma vez treinadas e seus parâmetros identificados, elas podem processar um montante de informações gigantesco e retornar uma saída em questão de segundos, de maneira muito mais eficiente que qualquer ser humano.

É nesse contexto que sua utilização se torna uma importante ferramenta pelos mais diversos operadores financeiros, uma vez que ela fornece, de maneira categórica, uma saída para qualquer problema para o qual ela tenha sido treinada. O fator humano, entretanto, não é dispensável; mas de vital importância para avaliar se o modelo representa adequadamente o fenômeno analisado – no caso o mercado financeiro – e se sua confiabilidade é, de fato, verdadeira.

Explicação

Em 1989, o engenheiro George Cybenko propôs aquilo que ficaria conhecido como o teorema da Aproximação Universal. Sua premissa pressupõe que uma rede neural, sobre determinadas condições, é capaz de aproximar qualquer função sobre a qual ela tenha sido treinada. Agora pensemos em um determinado caso de nosso interesse, como por exemplo, modelar o preço de uma ação. A teoria exige que para o funcionamento do modelo, ele deve receber como entrada os parâmetros que influenciam no preço da ação. Juntos, estes parâmetros irão gerar o espaço vetorial da função, devendo ser suficientes para a modelagem do fenômeno analisado.

Essa ideia serviu de base para a primeira parte deste desafio. Considerando a necessidade de incluir as componentes do espaço vetorial das funções analisadas, o grupo criou uma base de dados diversificada, a qual combinava dados de índices, análise técnica, câmbio, sazonalidade etc; de modo a reproduzir, da maneira mais fidedigna possível, o espaço vetorial da ação.

Não bastasse esta busca pela representatividade dos parâmetros, também buscou-se trazer para o desafio um dos mais inovadores elementos na área de inteligência artificial – o aprendizado por reforço. Nele, o modelo é confrontado recorrentemente com uma determinada situação, devendo ele propor uma solução. Se ela for boa, o algoritmo é recompensado e tende a reproduzi-la posteriormente; se não, é penalizado e parte em busca de novas soluções.

Posto isso, o grupo desenvolveu a seguinte estratégia na elaboração de um modelo de portfólio: considerando um universo finito de ações, busca-se criar um modelo de aprendizado por reforço que, munido de uma base de dados representativa, proponha diariamente o peso para cada ativo, procurando maximizar o retorno acumulado deste portfólio.

Execução

A primeira etapa deste trabalho correspondeu ao desenvolvimento da base de dados que iria compor o modelo. Na ausência de um terminal Bloomberg, a equipe desenvolveu seu próprio modelo de banco de dados em tempo real integrado com uma série de APIs como Yahoo Finance, B3, Banco Central etc; o qual é capaz de fornecer as mais diversas informações bem como realizar cálculos e transformações sobre elas. Esse atributo foi o coração do processo de criação das bases de dados, as quais foram utilizadas para treinar e avaliar o robô de 2016 até 2022.

Sua criação começava com a definição de três datas principais: a de início de treino, fim de treino e fim do teste. A de início de teste começava, por definição, no próximo dia útil depois do fim do treino. O processo utilizado consistia em selecionar as 30 ações de maior volume de operações na B3 considerando a data final de treino. Com eles, eram montadas duas bases – a de treino e de teste – ambas de mesmas features diferindo apenas na data de suas informações.

A data de começo de treino era, por definição, igual a dez anos antes da data de fim do treino. Porém, por limitações de disponibilidade de dados nas API's, este valor poderia ser reduzido a até 7 anos. Além disso, por este mesmo motivo, o universo de ativos operados poderia reduzir. Como consequência, observou-se um valor mínimo de 27 ocorrido em 2016. Este valor, entretanto, é pouco menor que o ideal de 30 estabelecido e não apresenta prejuízos ao modelo.

Tabela 1 – períodos das bases de dados

Ano avaliado	Quantidade de ativos	Intervalo de datas de treino	Intervalo de datas de teste
2016	27	06/05/2008 – 30/12/2015	05/01/2016 – 29/12/2016
2017	30	02/03/2010 – 29/12/2016	04/01/2017 – 28/12/2017
2018	30	02/03/2010 – 28/12/2017	02/01/2018 – 28/12/2018
2019	29	27/05/2011 – 28/12/2018	03/01/2019 – 30/12/2019
2020	30	01/06/2012 – 30/12/2019	02/01/2020 – 30/12/2020
2021	29	01/06/2012 – 30/12/2020	04/01/2021 – 30/12/2022
2022	30	09/01/2014 – 30/12/2021	03/01/2022 – 29/12/2022

Tabela 2 – componentes das bases de dados

Parâmetro	Períodos
Preço de abertura, fechamento, mínimo e máximo do ativo	1
Índice de força relativa (RSI)	14
Indicador de Momento	10
Indicador Commodity Channel Index (CCI)	20
Indicador Estocástico	14
Indicador Williams %R	14
Indicador MACD - valores da linha e do sinal	12 (rápido) e 26 (longo)
Diferença da banda superior e inferior de Bollinger	20
Cotação do Dólar	Variável
Índice Ibovespa	Variável

Índice S&P 500	Variável
Retorno diário do CDI	Variável
Índice Nasdaq	Variável
Valor do IPCA	Variável
Valor da taxa SELIC	Variável
Valor do IGPM	Variável
Dia da semana em formato numérico	-

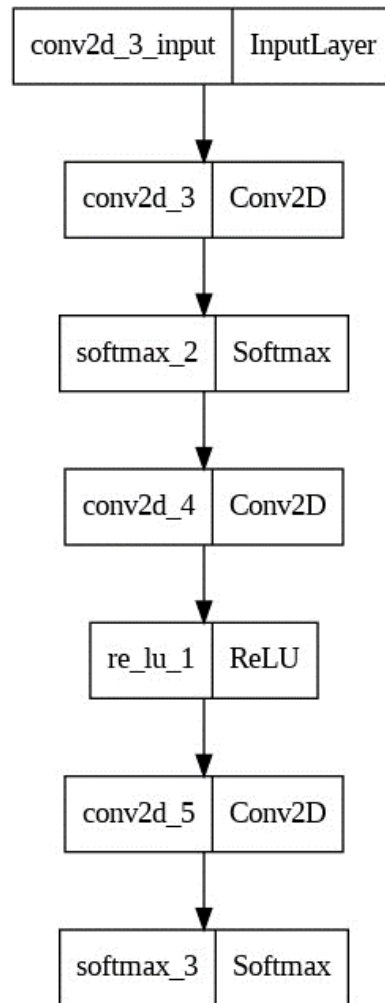
Destaca-se, de modo especial, o emprego de métodos de suavização de dados aplicados aos valores dos parâmetros com período definido como variável. Isto foi realizado com o intuito de melhorar a correlação deles com a variável de interesse (preço de fechamento). A técnica empregada consistia em analisar a média móvel simples e exponencial em diferentes períodos, bem como a aplicação de filtro de Kalman para diferentes valores de covariância. Assim, o parâmetro suavizado mais correlato com todas as ações era selecionado e passaria a compor a base de dados de treino, sendo suas propriedades usadas no ambiente de teste também.

Uma vez preparada a base de dados de treinamento e teste, partiu-se para o desenvolvimento do modelo de aprendizado por reforço a ser utilizado. No processo, grupo optou por utilizar ferramentas já desenvolvidas presentes em uma das mais famosas bibliotecas de aprendizado por reforço voltada a finanças – a FinRL. Como inspiração, o grupo baseou-se no trabalho desenvolvido no artigo “A General Portfolio Optimization Environment for FinRL”, um otimizador de portfólio desenvolvido de maneira análoga que guiou a execução deste projeto.

O processo começava com a definição do ambiente de operação – uma classe responsável por reproduzir todos os atributos do universo do mercado financeiro como, por exemplo, o retorno acumulado do período; juntamente com a atribuição de recompensas ou penalidades ao modelo, essenciais para o aprendizado. Sobre isso, este ocorre de maneira gradual, em passos seguidos um pelo outro e discretizadas pelos dias de treino. Sua entrada corresponde aos dados dos 50 períodos anteriores à data avaliada, e sua saída é um vetor de pesos para os ativos no portfólio para o dia seguinte. Se esta proposta se prova eficiente, obtém-se uma recompensa, do contrário, uma penalidade. A execução deste processo até a passagem por todos os períodos da base de dados corresponde a 1 episódio. Ao todo, o modelo de cada ano foi treinado durante 100 episódios, de modo a assegurar a máxima compreensão do fenômeno estudado.

De modo especial, destaca-se o cérebro do modelo composto por uma rede neural de 3 camadas. Seu funcionamento combinava técnicas de convolução – muito úteis para o reconhecimento de padrões nos vetores de entrada – juntamente com diferentes funções de ativação como a ReLU (que é computacionalmente eficiente e promove uma atualização dos pesos de maneira mais rápida) e softmax (útil para normalizar a saída e facilita sua interpretação probabilística). Juntos, estes atributos contribuíram para a elaboração de uma arquitetura de rápida em execução e eficiente em sua proposta inicial de previsão dos pesos do portfólio.

Imagem 1 – arquitetura da rede neural utilizada



Resultados

Uma vez criadas as bases de dados, bem como desenvolvida a arquitetura do modelo, partiu-se para o treinamento do mesmo com relação a cada ano a ser avaliado. Como consequência, foram treinados 7 modelos de mesma arquitetura responsáveis por avaliar os anos de 2016 a 2022. Com o treinamento de todos em modo paralelo, o processo levou cerca de 4h30 min. Já em testes anteriores, para o treinamento individual de um único modelo, este tempo ficava em aproximadamente 2h30 min.

Assim que a etapa de treinamento fora finalizada, partiu-se para a avaliação das métricas de performance no teste do modelo. Seu processo começava com a definição do ambiente de operação - de modo semelhante ao visto no treino – mas agora os parâmetros eram importados do arquivo salvo após o fim do respectivo treinamento. Em seguida, este ambiente era simulado para o banco de dados de teste, e seu peso previsto para cada dia no portfólio era armazenada em uma estrutura de dados em fila especificamente desenvolvida para isto. Em seguida, tanto o ambiente quanto esta estrutura de dados eram repassadas a um módulo responsável por gerar as métricas de backtest obtidas.

Backtest

Para a realização do backtest, algumas hipóteses relativas ao cenário de operação foram adotadas, as quais encontram-se listadas abaixo:

1. Liquidez Infinita: não há restrições quanto ao volume de um ativo a ser operado em uma operação de compra e venda.
2. Sem efeito de compra e demanda: a compra ou venda de um ativo não trará flutuações sobre o preço do mesmo.
3. As operações de compra e venda sempre se dão após o fechamento da bolsa considerando o último preço do dia, estando o ativo em posse ou liquidado já na abertura do próximo dia útil.
4. Ausência de custos operacionais: consideraram-se nulos os valores dos custos de corretagem e custódia. Como somente são realizadas operações do tipo 'long', custos de aluguel foram igualmente ignorados.

Tendo como base a fila dos vetores de alocação do portfólio para o dia previsto, era abstraído o valor do retorno relativo a cada ação e multiplicado pelo seu peso correspondente. Vale ressaltar que este vetor sempre tinha uma componente a mais, a qual corresponde a manutenção dos recursos financeiros em caixa e sem operação. Assumiu-se, nestes casos, retorno diário nulo para essa alocação.

Uma vez obtida a taxa total de retorno diário do portfólio, prosseguiu-se para a obtenção de algumas métricas. A primeira analisada foi a taxa de acerto ou hit ratio do modelo, a qual expressa o percentual de retorno positivo do modelo. Uma outra métrica também coletada corresponde ao índice de Sharpe anualizado, medida usada para avaliar o desempenho de um investimento em relação ao risco assumido. Sua vantagem em relação ao índice de acerto é que ela também considera o valor do retorno obtido, e não apenas seu sinal. Seu cálculo é dado pela razão entre a média dos retornos diários no ano pelo valor do desvio padrão deles, sendo em seguida multiplicado pela raiz quadrada de 252. Assim, obteve-se os seguintes dados:

Tabela 3 – Valores de hit Ratio e Sharpe Ratio do modelo

Ano avaliado	Hit Ratio (%)	Sharpe Ratio
2016	58.5	1.47
2017	51.7	1.39
2018	52.6	1.13
2019	48.8	0.49
2020	49.4	-0.09
2021	50.4	-0.23
2022	53.3	1.19

Por fim, avaliou-se o retorno acumulado de 2016 a 2022, de modo a avaliar variação final de capital ao longo dos anos. Comparou-se também com o acumulado do benchmark principal definido como o índice IBOV, bem como do CDI. Com isso, obteve-se os seguintes valores:

Ano avaliado	Retorno acumulado do Portfólio (%)	Retorno acumulado do IBOV (%)	Retorno acumulado do CDI (%)
2016	78.1	42.0	13.9
2017	53.2	24.1	9.8
2018	32.8	12.8	6.4
2019	10.1	26.6	5.9
2020	-18.0	0.6	2.7
2021	-13.36	-11.6	4.3
2022	45.4	5.9	12.3

Seu desempenho progressivo pode ser avaliado nos seguintes gráficos:

Imagem 2 – performance no ano de 2016



Imagem 3 – performance no ano de 2017



Imagem 4 – performance no ano de 2018




Imagem 5 – performance no ano de 2019




Imagem 6 – performance no ano de 2020



Imagem 7 – performance no ano de 2021




Imagem 8 – performance no ano de 2022



Imagem 9 – performance total (2016 – 2022)



Por fim, considerando a janela de teste de 2016 a 2022, o modelo obteve um retorno acumulado de 312%, o qual é consideravelmente superior ao observado para o IBOV de 137%, bem como para o CDI de 69%.

Conclusão

Considerando o modelo de portfólio desenvolvido neste projeto, pode-se concluir que ele cumpre de maneira positiva o objetivo proposto inicialmente. Seus resultados performaram de forma satisfatória, superando o benchmark do índice Ibovespa no período analisado. Além disso, é importante pontuar sua capacidade de reproduzir adequadamente os requisitos de implementação de qualquer estratégia quantitativa, como por exemplo, o cuidado na não reprodução de vieses típicos como Lookahead bias e Survivorship bias – especialmente tratados ao utilizar somente as informações disponíveis na data analisada, seja no treino, teste ou análise do backtest do modelo.

Entretanto, tal modelo ainda apresenta certas limitações que dificultam sua implementação em um cenário real, uma vez que a realidade simulada e listada nas hipóteses da seção de backtest difere da realidade. Ademais, outro fator limitante reside no período de rebalanceamento da carteira de ações que é diário, o que pode ser um impeditivo para sua utilização por grandes gestoras, embora ainda possível por meio de pessoas físicas.

Feitas tais considerações, vale, porém, destacar a escalabilidade deste projeto. Em novas versões, um incremento possível seria simplesmente expandir os parâmetros componentes da base de dados. Além disso, ao invés de treinar um único modelo para todos os ativos, pode-se treinar um para cada setor das ações listadas na B3. Assim, os ativos de fato operados poderiam ser, por exemplo, selecionados por meio gerenciadores de portfólio ponderados pelo peso previsto e pela cointegração dos ativos.

Por fim, é inegável o potencial do trabalho desenvolvido. Sua implementação de um modelo de aprendizado por reforço ajuda a trazer para o mundo das finanças uma das tecnologias mais proeminentes do século XXI, contribuindo, dessa forma, para o fortalecimento e expansão da análise quantitativa frente ao mercado financeiro.

Referências

- [1] Cybenko, George. 1989. Approximation by superpositions of a sigmoidal function. Math. Control Signal Systems 2, 303–314
- [2] Costa, C. S. B., & Costa, A. H. R. (2023). POE: A General Portfolio Optimization Environment for FinRL. In: Brazilian Workshop on Artificial Intelligence in Finance (BWAIF), 2., 2023, João Pessoa/PB. Anais [...]. Porto Alegre: Sociedade Brasileira de Computação, 2023, p. 132-143.
- [3] JANSEN, Stefan. Machine Learning for Algorithmic Trading, Second Edition. Birmingham, UK: Packt Publishing Ltd., 2020.
- [4] HILPISCH, Yves. Artificial Intelligence in Finance. Sebastopol, CA: O'Reilly Media, Inc., 2021.